

## EXAMEN PARTIEL

---

Instructions : – Une feuille aide-mémoire recto verso manuscrite est permise ;

– Durée de l'examen : 2 h 50.

Pondération : Cet examen compte pour 30% de la note finale.


---

### Question 1 (15 points sur 100)

Soit un problème de classement à deux classes et en une dimension, dont les vraisemblances de classe sont décrites par les densités de probabilité suivantes :

$$p(x|C_1) = \begin{cases} 1 & x \in [1, 2[ \\ 0 & \text{autrement} \end{cases}, \quad p(x|C_2) = \begin{cases} 0,5 & x \in [0,75, 2,75[ \\ 0 & \text{autrement} \end{cases},$$

qui sont représentées dans ce qui suit.



- (5) (a) Supposons que les probabilités a priori sont égales ( $P(C_1) = P(C_2) = 0,5$ ), donnez la règle de décision à utiliser selon cette modélisation pour assigner une donnée  $x$  à la classe  $C_1$  ou  $C_2$ .
- (5) (b) Toujours en supposant des probabilités a priori égales, donnez les équations des probabilités a posteriori ( $P(C_i|x)$ ) pour les deux classes.
- (5) (c) Supposons maintenant que les probabilités a priori sont différentes, avec  $P(C_1) = 0,25$  et  $P(C_2) = 0,75$ . Donnez les probabilités a posteriori pour les deux classes et la règle de décision associée.

## Question 2 (25 points sur 100)

Soit un réseau de neurones de type RBF pour deux classes, composé d'une couche cachée de  $R$  neurones de type gaussien, suivi d'une couche de sortie d'un neurone avec fonction d'activation linéaire. La valeur de la sortie pour un tel réseau de neurones pour une valeur d'entrée  $\mathbf{x}$  est donnée par l'équation suivante,

$$h(\mathbf{x}) = \sum_{i=1}^R w_i \phi_i(\mathbf{x}) + w_0 = \sum_{i=1}^R w_i \exp \left[ -\frac{\|\mathbf{x} - \mathbf{m}_i\|^2}{2s_i^2} \right] + w_0,$$

où :

- $\mathbf{m}_i$  est la valeur du centre du  $i$ -ème neurone gaussien de la couche cachée ;
- $s_i$  est l'étalement du  $i$ -ème neurone gaussien ;
- $w_i$  est le poids connectant le  $i$ -ème neurone gaussien de la couche cachée au neurone de sortie ;
- $w_0$  est le biais du neurone de sortie.

Supposons que l'on fixe les étalements  $s_i$  à des valeurs prédéterminées et que l'on veut apprendre les valeurs  $w_i$ ,  $w_0$  et  $\mathbf{m}_i$  par descente du gradient, en utilisant comme critère l'erreur quadratique moyenne,

$$E = \frac{1}{2N} \sum_{\mathbf{x}^t \in \mathcal{X}} (e^t)^2 = \frac{1}{2N} \sum_{\mathbf{x}^t \in \mathcal{X}} [r^t - h(\mathbf{x}^t)]^2,$$

où :

- $r^t \in \mathbb{R}$  est la valeur désirée pour le neurone de sortie du réseau ;
- $\mathcal{X}$  est l'ensemble des  $N$  données d'entraînement.

- (13) (a) Développez les équations permettant de **mettre à jour les poids**  $w_i$  et  $w_0$  du neurone de sortie par descente du gradient, avec un taux d'apprentissage  $\eta$ , en utilisant le critère de l'erreur quadratique moyenne.
- (12) (b) Développez les équations permettant de **mettre à jour les valeurs des centres**  $\mathbf{m}_i$  des neurones gaussiens de la couche cachée par descente du gradient, en utilisant le critère de l'erreur quadratique moyenne.


## Question 3 (32 points sur 100)

Soit le jeu de données suivant, en deux dimensions :

$$\begin{aligned} \mathbf{x}^1 &= [0,5 \ 0,3]^\top, & \mathbf{x}^2 &= [0,4 \ 0,3]^\top, & \mathbf{x}^3 &= [0,3 \ 0,35]^\top, & \mathbf{x}^4 &= [0,4 \ 0,4]^\top, \\ \mathbf{x}^5 &= [0,45 \ 0,45]^\top, & \mathbf{x}^6 &= [0,5 \ 0,35]^\top, & \mathbf{x}^7 &= [0,55 \ 0,45]^\top, & \mathbf{x}^8 &= [0,4 \ 0,55]^\top. \end{aligned}$$

Les étiquettes de ces données sont  $r^1 = r^2 = r^3 = r^4 = -1$  et  $r^5 = r^6 = r^7 = r^8 = 1$ .

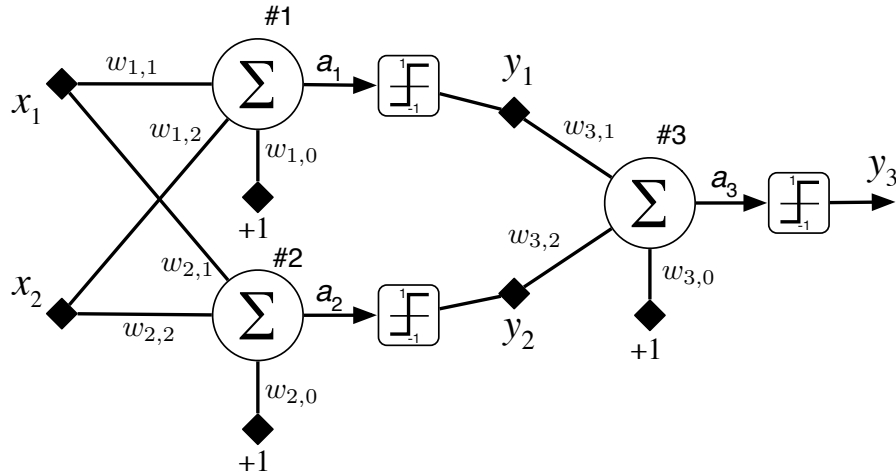
Le graphique ici-bas présente le tracé de ces données.



- (10) (a) Soit un réseau de neurones utilisant la fonction signe comme fonction d'activation :

$$f_{\text{sgn}}(a) = \text{sgn}(a) = \begin{cases} 1 & a \geq 0 \\ -1 & a < 0 \end{cases}.$$

Supposons que l'on veut entraîner le réseau suivant à trois neurones avec cette fonction d'activation signe, pour classifier les données présentées ci-haut, selon le schéma suivant.



Supposons les valeurs de poids  $w_{3,1} = 1$  et  $w_{3,2} = 1$ , et du biais  $w_{3,0} = -1,5$ . Déterminez les poids et biais des neurones 1 et 2 afin d'obtenir un taux de classement correct de 100 % sur les données.

- (10) (b) Tracez les régions de décision selon les données d'entraînement présentée en préambule de la question pour un classifieur de type plus proche voisin (avec un seul voisin,  $k = 1$ ) utilisant une distance euclidienne. Tracez le tout dans la **feuille de réponse fournie** (et non dans l'énoncé courant). Donnez également le taux de classement selon une méthodologie *leave-one-out* avec cette configuration, sur ces données.

- (12) (c) Nous obtenons le résultat suivant en effectuant l'entraînement d'un SVM linéaire à **marge douce** avec ces données, avec comme valeur de paramètre de régularisation  $C = 200$  :

$$\alpha^1 = 180, \quad \alpha^2 = 0, \quad \alpha^3 = 0, \quad \alpha^4 = 200, \quad \alpha^5 = 180, \quad \alpha^6 = 200, \quad \alpha^7 = 0, \quad \alpha^8 = 0, \\ w_0 = -11,6.$$

En utilisant la feuille de réponse fournie, tracez les éléments suivants :

- Frontière de décision du SVM (droite continue, —);
- Frontières de la marge (droites en traits pointillés, ----);
- Vecteurs de support (encerclez les points, ○);
- Données dans la marge (encadrez les points, □).

### Question 4 (28 points sur 100)

Répondez aussi brièvement et clairement que possible aux questions suivantes.

- (4) (a) Expliquez en quoi consiste la régularisation dans un contexte d'apprentissage supervisé.
- (4) (b) Dans un contexte de classement paramétrique s'appuyant sur des modèles de densité de probabilité des données selon les classes, la règle de Bayes est souvent utilisée de la façon suivante :

$$\underbrace{P(C|\mathbf{x})}_{\text{a posteriori}} = \frac{\overbrace{P(C)}^{\text{a priori}} \overbrace{p(\mathbf{x}|C)}^{\text{vraisemblance}}}{\underbrace{p(\mathbf{x})}_{\text{évidence}}}.$$

Expliquez pourquoi l'évidence  $p(\mathbf{x})$  de cette formulation est généralement ignorée lorsqu'il vient le moment de définir la règle de décision (fonction  $h_i(\mathbf{x})$ ).

- (4) (c) Supposons un classement paramétrique basé sur des lois normales multivariées, où l'estimation de la matrice de covariance  $S$  est partagée (la même) entre toutes les classes. Indiquez l'équation pour calculer cette estimation de la matrice de covariance partagée à partir d'un jeu de données étiquetées pour le classement.
- (4) (d) Dans un contexte de classement par les  $k$ -plus proches voisins, expliquez l'effet du nombre de voisins  $k$  sur le classement et les frontières de décision.
- (4) (e) Expliquez le lien principal que l'on peut établir entre la régression logistique et le classement paramétrique.
- (4) (f) Dans un contexte de classement avec SVM à marges douces, expliquez comment on interprète les variables *slacks*  $\xi^t$ .
- (4) (g) Expliquez la différence entre un apprentissage par lots (*batch*) et un apprentissage en ligne dans un réseau de neurones.