

EXAMEN FINAL

Instructions : – Une feuille aide-mémoire recto-verso manuscrite est permise ;
– Durée de l'examen : 2 h 50.

Pondération : Cet examen compte pour 35% de la note finale.


Question 1 (15 points sur 100)

Soit le jeu de données $\mathcal{X} = \{\mathbf{x}^t, r^t\}_{t=1}^6$ présenté ci-bas.

$$\mathbf{x}^1 = \begin{bmatrix} 7 \\ 5 \end{bmatrix}, \quad r^1 = -1, \quad \mathbf{x}^2 = \begin{bmatrix} 10 \\ 8 \end{bmatrix}, \quad r^2 = -1, \quad \mathbf{x}^3 = \begin{bmatrix} 13 \\ 9 \end{bmatrix}, \quad r^3 = -1,$$

$$\mathbf{x}^4 = \begin{bmatrix} 8 \\ 13 \end{bmatrix}, \quad r^4 = 1, \quad \mathbf{x}^5 = \begin{bmatrix} 6 \\ 9 \end{bmatrix}, \quad r^5 = 1, \quad \mathbf{x}^6 = \begin{bmatrix} 2 \\ 10 \end{bmatrix}, \quad r^6 = 1$$


La figure suivante trace ces points en deux dimensions.



Supposons que l'on veut classer ces données avec un classifieur de type séparateur à vastes marges (SVM) utilisant un noyau linéaire ($K(\mathbf{x}, \mathbf{x}') = \langle \mathbf{x}, \mathbf{x}' \rangle$), sans marge floue.

- (5) (a) Dans votre **cahier de réponse**, tracez les données du jeu \mathcal{X} , les marges géométriques maximales obtenues avec le SVM, l'hyperplan séparateur correspondant, et encerclez les données agissant comme vecteurs de support.

Solution:



- (10) (b) Donnez les valeurs des poids w et biais w_0 correspondant au discriminant linéaire maximisant les marges géométriques tracées en a).
Indice : il n'est pas nécessaire de calculer les α^i pour répondre à la question.

Solution: Trois données sont identifiées comme vecteurs de support : x^1 , x^2 et x^5 . En travaillant directement dans l'espace d'entrée, ceci nous donne trois équations et trois inconnus.

$$\begin{aligned} h(x^1) &= w_2 x_2^1 + w_1 x_1^1 + w_0 = 5w_2 + 7w_1 + w_0 = -1 \\ h(x^2) &= w_2 x_2^2 + w_1 x_1^2 + w_0 = 8w_2 + 10w_1 + w_0 = -1 \\ h(x^5) &= w_2 x_2^5 + w_1 x_1^5 + w_0 = 9w_2 + 6w_1 + w_0 = 1 \end{aligned}$$

La résolution de ce système d'équation peut se faire par la suivante.

$$(8 \times \text{EQ1}) - (5 \times \text{EQ2}) : (40 - 40)w_2 + (56 - 50)w_1 + (8 - 5)w_0 = -8 + 5 \\ 6w_1 + 3w_0 = -3$$

$$(9 \times \text{EQ2}) - (8 \times \text{EQ3}) : (72 - 72)w_2 + (90 - 48)w_1 + (9 - 8)w_0 = -9 - 8 \\ 42w_1 + w_0 = -17$$

$$\text{L1} - (3 \times \text{L2}) : (6 - 126)w_1 + (3 - 3)w_0 = -3 + 51 \\ -120w_1 = 48 \quad \Rightarrow \quad w_1 = -0,4$$

$$\text{L1} - (6 \times \text{L3}) : (6 - 6)w_1 + (3 - 0)w_0 = -3 - 6(-0,4) \\ 3w_0 = -3 + 2,4 \quad \Rightarrow \quad w_0 = -0,2$$

$$\text{EQ1} - (7 \times \text{L3}) - \text{L4} : 5w_2 + (7 - 7)w_1 + (1 - 1)w_0 = -1 - 7(-0,4) - (-0,2) \\ 5w_2 = -1 + 2,8 + 0,2 = 2 \quad \Rightarrow \quad w_2 = 0,4$$

La résolution de ce système d'équations nous donne les valeurs suivantes :

$$w_2 = 0,4, w_1 = -0,4, w_0 = -0,2.$$

Question 2 (10 points sur 100)

Soit le classifieur à noyau suivant, utilisant le critère d'erreur du perceptron.

$$h(\mathbf{x}|\boldsymbol{\alpha}, w_0) = \sum_{\mathbf{x}^s \in \mathcal{X}} \alpha^s r^s K(\mathbf{x}^s, \mathbf{x}) + w_0, \\ \alpha^t \geq 0 \quad \forall t,$$

avec :

$$E(\boldsymbol{\alpha}, w_0 | \mathcal{X}) = - \sum_{\mathbf{x}^t \in \mathcal{Y}} r^t h(\mathbf{x}^t | \boldsymbol{\alpha}, w_0) + \lambda \frac{1}{2} \sum_{\alpha^t \in \boldsymbol{\alpha}} (\alpha^t)^2, \\ \mathcal{Y} = \{\mathbf{x}^t \in \mathcal{X} | r^t h(\mathbf{x}^t | \boldsymbol{\alpha}, w_0) < 0\}.$$

Donnez les équations pour mettre à jour les $\boldsymbol{\alpha}$ et w_0 selon une descente du gradient.

Solution:

$$\begin{aligned}
\frac{\partial E}{\partial \alpha^i} &= \frac{\partial}{\partial \alpha^i} \left[- \sum_{\mathbf{x}^t \in \mathcal{Y}} r^t \left(\sum_{\mathbf{x}^s \in \mathcal{X}} \alpha^s r^s K(\mathbf{x}^s, \mathbf{x}^t) + w_0 \right) + \lambda \frac{1}{2} \sum_{\alpha^t \in \alpha} (\alpha^t)^2 \right] \\
&= - \sum_{\mathbf{x}^t \in \mathcal{Y}} r^t r^i K(\mathbf{x}^i, \mathbf{x}^t) + \lambda \alpha^i \\
\Delta \alpha^i &= -\eta \frac{\partial E}{\partial \alpha^i} = \eta \left[\sum_{\mathbf{x}^t \in \mathcal{Y}} r^t r^i K(\mathbf{x}^i, \mathbf{x}^t) - \lambda \alpha^i \right] \\
\frac{\partial E}{\partial w_0} &= \frac{\partial}{\partial w_0} \left[- \sum_{\mathbf{x}^t \in \mathcal{Y}} r^t \left(\sum_{\mathbf{x}^s \in \mathcal{X}} \alpha^s r^s K(\mathbf{x}^s, \mathbf{x}^t) + w_0 \right) + \lambda \frac{1}{2} \sum_{\alpha^t \in \alpha} (\alpha^t)^2 \right] \\
&= - \sum_{\mathbf{x}^t \in \mathcal{Y}} r^t \\
\Delta w_0 &= -\eta \frac{\partial E}{\partial w_0} = \eta \sum_{\mathbf{x}^t \in \mathcal{Y}} r^t
\end{aligned}$$

Question 3 (15 points sur 100)

Dans le cours, il a été avancé qu'un perceptron multi-couches (PMC) avec plusieurs couches de neurones et utilisant une fonction de transfert linéaire ($f_{lin}(a) = a$) pour tous les neurones peut être simplifié comme PMC à une seule couche de neurones avec fonction de transfert linéaire. Démontrez que cette affirmation est vraie à partir des équations du PMC modélisant la propagation des données de l'entrée vers la sortie.

Solution: Pour répondre à cette question, on va d'abord démontrer qu'un PMC à deux couches avec fonction de transfert linéaire peut être simplifié en un PMC à une couche. L'équation décrivant la propagation des données de l'entrée vers la sortie y_k^t dans un neurone k sur la couche l de la donnée \mathbf{x}^t est la suivante :

$$y_k^t = f \left(\sum_{j=1}^R w_{k,j} y_j^t + w_{k,0} \right),$$

où y_j^t représente les sorties des neurones de la couche précédente, soit la couche $l-1$, pour la donnée. Avec une fonction de transfert linéaire la fonction se simplifie par ce qui suit :

$$y_k^t = \sum_{j=1}^R w_{k,j} y_j^t + w_{k,0}.$$

Si on substitue la même équation pour les sortie y_j^t de la couche k , on obtient l'équation

suivante :

$$\begin{aligned}
 y_k^t &= \sum_{j=1}^R w_{k,j} \left(\sum_{i=1}^Q w_{j,i} y_i^t + w_{j,0} \right) + w_{k,0} \\
 &= \left(\sum_{j=1}^R w_{k,j} \sum_{i=1}^Q w_{j,i} y_i^t \right) + \left(\sum_{j=1}^R w_{k,j} w_{j,0} \right) + w_{k,0} \\
 &= \sum_{i=1}^Q \left(\sum_{j=1}^R w_{k,j} w_{j,i} \right) y_i^t + \left(\sum_{j=1}^R w_{k,j} w_{j,0} + w_{k,0} \right),
 \end{aligned}$$

où y_i^t représente la sortie de la couche $l-2$, soit la couche précédant la couche du neurone j . On peut alors poser les variables suivantes :

$$\begin{aligned}
 w'_{k,i} &= \sum_{j=1}^R w_{k,j} w_{j,i}, \\
 w'_{k,0} &= \sum_{j=1}^R w_{k,j} w_{j,0} + w_{k,0},
 \end{aligned}$$

ce qui nous permet de réexprimer l'équation pour le neurone k directement en fonction des neurones de la couche $l-2$:

$$y_k^t = \sum_{i=1}^Q w'_{k,i} y_i^t + w'_{k,0}.$$

De cette façon on vient de simplifier les couches l et $l-1$ en une seule couche de neurones linéaires connectés directement sur la sortie des neurones de la couche $l-2$.

Par induction, on peut ainsi simplifier successivement toutes les couches du PMC deux à deux, pour obtenir un réseau simplifié avec une seule couche de neurones avec fonction de transfert linéaire.

Question 4 (15 points sur 100)

La fonction $h_{j,i}$ correspond à la décision du classifieur h_j concernant la classe C_i . Ainsi, pour un problème à trois classes, les fonctions $h_{j,1}$, $h_{j,2}$ et $h_{j,3}$ retournent les valeurs de la décision du classifieur h_j pour les classes C_1 , C_2 et C_3 , respectivement.

- (5) (a) Supposons que l'on bâtit un ensemble de $L = 5$ classifieurs prenant des décisions sur $K = 3$ classes. La fonction \bar{h}_i retourne le résultat de l'ensemble pour la classe C_i . Pour

une donnée \mathbf{x} particulière, on obtient les résultats suivants avec cet ensemble.

	C_1	C_2	C_3
$h_{1,i}(\mathbf{x})$	0,3	0,5	0,45
$h_{2,i}(\mathbf{x})$	0,4	0,4	0,35
$h_{3,i}(\mathbf{x})$	0,45	0,6	0,5
$h_{4,i}(\mathbf{x})$	0,1	0,2	0,15
$h_{5,i}(\mathbf{x})$	0,3	0,2	0,3

Pour chacune des fonctions de combinaison suivantes, utilisées pour calculer le résultat de la fonction de l'ensemble par classe \bar{h}_i , donnez les décisions de classement pour la donnée \mathbf{x} :

1. somme ;
2. maximum ;
3. médiane.

Solution: Les résultats pour chaque fonction de combinaison sont les suivants :

	C_1	C_2	C_3	décision
$h_{1,i}(\mathbf{x})$	0,3	0,5	0,45	
$h_{2,i}(\mathbf{x})$	0,4	0,4	0,35	
$h_{3,i}(\mathbf{x})$	0,45	0,6	0,5	
$h_{4,i}(\mathbf{x})$	0,1	0,2	0,15	
$h_{5,i}(\mathbf{x})$	0,3	0,2	0,3	
$\bar{h}_i(\mathbf{x}) = \sum_{j=1}^L h_{j,i}(\mathbf{x})$	1,55	1,9	1,75	C_2
$\bar{h}_i(\mathbf{x}) = \max_{j=1}^L h_{j,i}(\mathbf{x})$	0,45	0,6	0,5	C_2
$\bar{h}_i(\mathbf{x}) = \text{med}_{j=1}^L h_{j,i}(\mathbf{x})$	0,3	0,4	0,35	C_2

- (5) (b) Supposons maintenant que les décisions sont binaires, de sorte que les valeurs pour chaque classe des classifieurs de l'ensemble sont $h_{j,i}(\mathbf{x}) \in \{0,1\}$, et que l'on obtienne les résultats suivants pour la donnée \mathbf{x} pour un ensemble de $L = K = 3$ classifieurs.

	C_1	C_2	C_3
$h_{1,i}(\mathbf{x})$	0	1	1
$h_{2,i}(\mathbf{x})$	0	1	0
$h_{3,i}(\mathbf{x})$	0	0	1

Si cet ensemble est entraîné selon une approche revenant à *un contre tous*, avec la matrice de décision suivante,

$$\mathbf{W} = \begin{bmatrix} +1 & -1 & -1 \\ -1 & +1 & -1 \\ -1 & -1 & +1 \end{bmatrix},$$

donnez la décision de classement pour cette donnée.

Solution: La décision de l'ensemble pour la donnée est calculé selon l'équation

$$\bar{h}_i(\mathbf{x}) = \sum_j w_{i,j} h_{j,i}(\mathbf{x}).$$

Pour la donnée \mathbf{x} , le résultat est $\bar{h}_1(\mathbf{x}) = 0$, $\bar{h}_2(\mathbf{x}) = 0$ et $\bar{h}_3(\mathbf{x}) = 0$. Il y a donc ambiguïté, la donnée ne peut donc pas être assignée à une classe.

- (5) (c) Supposons maintenant que l'on veut utiliser une approche avec code de correction d'erreur comportant huit classifieurs. On a déjà établi les sept première colonnes de la matrice de décision \mathbf{W} comme suit :

$$\mathbf{W} = \begin{bmatrix} +1 & -1 & -1 & +1 & +1 & -1 & +1 & ? \\ -1 & +1 & -1 & +1 & -1 & +1 & -1 & ? \\ -1 & -1 & +1 & -1 & +1 & +1 & +1 & ? \end{bmatrix}.$$

Déterminez les valeurs sur la dernière colonnes de la matrice de décision permettant de tolérer jusqu'à deux erreurs par les classifieurs de base.

Solution: Selon cette matrice, les distances de Hamming entre les différentes lignes sont les suivantes :

- Ligne 1 vs 2 : distance de 5 ;
- Ligne 1 vs 3 : distance de 4 ;
- Ligne 2 vs 3 : distance de 5.

Il faut donc augmenter la distance de Hamming entre les lignes 1 et 3. À cette fin, on doit donc faire en sorte que les lignes 1 et 3 aient une valeur différente pour le neuvième colonne. Ceci nous permet de tolérer $\lfloor (5 - 1)/2 \rfloor = 2$ erreurs. Une solution possible pour compléter la matrice de décision est donc :

$$\mathbf{W} = \begin{bmatrix} +1 & -1 & -1 & +1 & +1 & -1 & +1 & +1 \\ -1 & +1 & -1 & +1 & -1 & +1 & -1 & -1 \\ -1 & -1 & +1 & -1 & +1 & +1 & +1 & -1 \end{bmatrix}.$$

Une alternative valable (parmi plusieurs autres) serait :

$$\mathbf{W} = \begin{bmatrix} +1 & -1 & -1 & +1 & +1 & -1 & +1 & -1 \\ -1 & +1 & -1 & +1 & -1 & +1 & -1 & -1 \\ -1 & -1 & +1 & -1 & +1 & +1 & +1 & +1 \end{bmatrix}.$$

Question 5 (45 points sur 100)

Répondez aussi brièvement et clairement que possible aux questions suivantes.

- (3) (a) Dans les séparateurs à vaste marge (SVM), utilisant la formulation avec marge douce, que

représente une valeur de la variable *slack* ξ^t lorsqu'elle est comprise dans $0 < \xi^t \leq 1$?

Solution: Une valeur $\xi^t \in]0,1]$ indique que la donnée \mathbf{x}^t associée à la variable est bien classée par le SVM (du bon côté de l'hyperplan séparateur), mais qu'elle est dans la marge.

- (3) (b) Avec l'analyse en composantes principales à noyau, on effectue une extraction des vecteurs propres et valeurs propres de la matrice de Gram normalisée. Indiquez combien de valeurs comporte la première composante principale extraite à l'aide de cette approche.

Solution: La première composante principale comporte N données, soit le nombre de données comprises dans le jeu de données et utilisées pour calculer la matrice de Gram.

- (3) (c) Indiquez précisément quel élément de l'algorithme de rétropropagation des erreurs du perceptron multi-couches fait en sorte qu'on le qualifie d'algorithme stochastique.

Solution: Le perceptron multi-couche est un algorithme stochastique car les poids initiaux du réseau de neurones sont initialisés aléatoirement.

- (3) (d) Dans l'algorithme de rétropropagation des erreurs du perceptron multi-couches, on utilise la règle de chaînage des dérivées pour calculer la correction à appliquer aux poids et biais du réseau. Par exemple, la correction de poids sur une couche de sortie se calcule à partir des dérivées partielles données dans l'équation suivante,

$$\frac{\partial E^t}{\partial w_{j,i}} = \frac{\partial E^t}{\partial e_j^t} \frac{\partial e_j^t}{\partial y_j^t} \frac{\partial y_j^t}{\partial a_j^t} \frac{\partial a_j^t}{\partial w_{j,i}}.$$

Quelle est la valeur de la dérivée partielle $\partial a_j^t / \partial w_{j,i}$ dans cette équation.

Solution: La dérivée partielle $\frac{\partial a_j^t}{\partial w_{j,i}}$ représente la valeur de la sortie du sommateur du neurone, avant qu'il soit appliqué comme entrée à la fonction de transfert, selon le poids $w_{j,i}$, relié à la sortie y_i de la couche précédente. Cette dérivée partielle est calculée comme suit :

$$\frac{\partial a_j^t}{\partial w_{j,i}} = \frac{\partial}{\partial w_{j,i}} \sum_{i=1}^R w_{j,i} y_i^t + w_{j,0} = y_i^t.$$

Sa valeur est donc y_i^t , soit la sortie du neurone i de la couche précédente pour la donnée \mathbf{x}^t .

- (3) (e) Dans les méthodes par ensemble, il est démontré que la variance des performance d'un ensemble \bar{h} formé de L classifieurs individuels h_j décroît selon la taille de l'ensemble selon

$$\text{Var}(\bar{h}) = \frac{1}{L} \text{Var}(h_j).$$

Cette formulation fait cependant que la réponse des classifieurs individuels h_j respecte l'hypothèse iid (identiquement et indépendamment distribués). Indiquez en vos propres mots ce que signifie cette hypothèse dans le contexte présent de classement avec ensembles.

Solution: L'hypothèse iid sur la réponse des classifieurs individuels signifie qu'il n'y a aucune corrélation entre les sorties des classifieurs, de sorte qu'un classifieur h_i n'a pas plus de chance de se tromper sur une donnée x si un autre classifieur fait une erreur de classement sur cette donnée ou non. De cette façon, les réponses, et donc les erreurs de classement, sont indépendantes d'un classifieur à l'autre, ce qui est une hypothèse forte.

- (3) (f) Avec l'algorithme AdaBoost, on modifie une probabilité p_j^t qu'une donnée x^t soit échantillonnée pour entraîner un classifieur à l'itération j . Indiquez de quelle façon, d'un point de vue conceptuel, cette probabilité est modifiée à chaque itération de l'algorithme.

Solution: La probabilité p_j^t est augmentée à une itération particulière si la donnée x^t est mal classée par le classifieur h_j généré à cette itération. Par la normalisation des probabilités, la valeur de p_j^t se trouve également à être diminuée si la donnée est bien classée par le classifieur.

- (3) (g) Lorsque l'on fait des expérimentations avec des algorithmes d'apprentissage supervisé pour faire du classement, on effectue souvent du partitionnement des ensembles de données avec **stratification**, où l'on respecte les proportions des données selon les différentes classes du problème (probabilités *a priori*). Indiquez pourquoi cette approche est souhaitable dans un contexte d'expérimentation et d'analyse, comparativement à un partitionnement sans stratification.

Solution: Le partitionnement avec stratification permet d'éliminer certaines variations dans la performances des algorithmes de classement liées à la proportion des données selon les classes. En effet, certains algorithmes peuvent être sensibles à la balance entre les classes dans les jeux de données, qui est un facteur incontrôlable, dont on veut minimiser l'impact sur les résultats.

- (3) (h) Dans le test de l'Analyse de variance (ANOVA), on veut comparer plusieurs algorithmes de classement, en tentant de vérifier l'hypothèse H_0 à l'effet que les moyennes des performances μ_j pour chaque classifieur sont égales. Pour vérifier cette hypothèse, on calcule deux estimateurs σ^2 de la variance des résultats pour chaque classifieur. Indiquez clairement ce que sont chacun de ces estimateurs de la variance et de quelle façon on les utilise pour déterminer si l'hypothèse H_0 est valide.

Solution: Le premier estimateur de la variance σ^2 est calculé en supposant que l'hypothèse H_0 est valide, soit que les moyennes des performances μ_j pour chaque classifieur

sont égales. Le deuxième estimateur de la variance σ^2 est estimé en ignorant cette hypothèse, supposant que les moyennes des performances μ_j peuvent différer d'un classifieur à l'autre. Ainsi, si le premier estimateur σ^2 est statistiquement identique au deuxième estimateur σ^2 , l'hypothèse H_0 s'avère être vérifiée, autrement elle est invalidée.

- (3) (i) Indiquez précisément les variables formant le modèle λ d'un modèle de Markov caché.

Solution: Un modèle de Markov caché est formé des variables $\lambda = \{\mathbf{A}, \mathbf{B}, \mathbf{\Pi}\}$, soit les probabilités de transitions entre états \mathbf{A} , les probabilités d'observations \mathbf{B} et les probabilités d'état initial $\mathbf{\Pi}$.

- (3) (j) Selon une méthode d'évaluation des performances de type *leave-one-out*, indiquez combien de fois une données particulière $\mathbf{x}^t \in \mathcal{X}$ de l'ensemble sera utilisée pour entraîner le classifieur évalué.

Solution: La donnée \mathbf{x}^t sera utilisée dans pour l'entraînement $N - 1$ fois, étant utilisé fois supplémentaire comme donnée de test, où N est le nombre de données dans l'ensemble \mathcal{X} .

- (3) (k) Dans le problème d'évaluation avec un modèle de Markov caché, on veut évaluer la probabilité $P(O|\lambda)$ d'avoir un certain séquence d'observations O avec le modèle λ . Cette probabilité peut se calculer selon l'équation suivante,

$$P(O|\lambda) = \sum_{\forall S} P(O, S|\lambda).$$

Cependant, le calcul de cette probabilité n'est pas tractable, computationnellement parlant. Indiquez comment on doit procéder pour évaluer la probabilité $P(O|\lambda)$ selon la méthode vue en classe, qui comporte une complexité algorithmique raisonnable.

Solution: La procédure avant permet de calculer la probabilité $P(O|\lambda)$ en stockant des résultats intermédiaires dans une variable $\alpha_t(i) \equiv P(\{o_1, \dots, o_t\}, s_t = S_i|\lambda)$, représentant la probabilité d'observer la partie de la séquence allant jusqu'au temps t , en supposant que l'on est dans l'état S_i . On peut calculer les $\alpha_t(i)$ récursivement, selon les valeurs $\alpha_{t-1}(j)$, de sorte que les calculs seront considérablement réduits.

- (3) (l) L'algorithme Baum-Welch permet de calculer le modèle λ d'un modèle de Markov caché à partir d'observations. Cet algorithme implique le calcul d'une probabilité $\xi_t(i, j)$. Indiquez ce que signifie précisément cette probabilité.

Solution: La probabilité $\xi_t(i, j) \equiv P(s_t = S_i, s_{t+1} = S_j|O, \lambda)$ représente la probabilité d'être dans l'état S_i au temps t et d'être ensuite dans l'état S_j au temps $t + 1$, étant donné le modèle λ et une séquence particulière d'observations O .

- (3) (m) Indiquez ce que représente précisément $Q(s,a)$ dans un contexte d'apprentissage par renforcement.

Solution: $Q(s,a)$ représente la fonction de valeur d'action, soit l'estimation de l'espérance de la récompense à long terme associée à effectuer l'action a dans l'état s .

- (3) (n) Selon Bellman, la valeur d'une action dans un certain état est donnée par :

$$Q^*(s,a) = \sum_{s'} \mathcal{P}_{ss'}^a \left[\mathcal{R}_{ss'}^a + \gamma \max_{a'} Q^*(s',a') \right].$$

Indiquez pourquoi il n'est pas possible d'appliquer directement cette équation dans le contexte où l'on ne possède pas de modèle satisfaisant de l'environnement.

Solution: Cette équation requiert de connaître les probabilités de transitions $\mathcal{P}_{ss'}^a$ entre l'état s et s' lorsque l'on effectue l'action a . Pour connaître ces probabilités de transitions, on doit avoir un modèle précis de l'environnement. De même, on doit également connaître la récompense immédiate espérée $\mathcal{R}_{ss'}^a$, qui elle aussi requiert avoir un modèle de l'environnement.

- (3) (o) Expliquez de quelle façon on détermine les actions effectuées par un agent dans un contexte d'apprentissage par renforcement, lorsque l'agent utilise une politique dite ϵ -greedy.

Solution: La politique ϵ -greedy consiste à choisir une action au hasard selon une probabilité ϵ , et autrement choisir l'action optimale selon les valeurs d'action $Q(s,a)$ actuelles.